

Vimos la clase pasada:

Teorema: Dada $A \in \mathbb{R}^{n \times m}$, $b \in \mathbb{R}^n$
son equivalentes:

1) $a^* \in \mathbb{R}^m$ minimiza $\|Ax - b\|_2$

2) a^* es solución de $A^t A x = A^t b$

Además, si las columnas de A
son li, la solución a^* de $A^t A x = A^t b$
existe y es única. Notar $A^t A \in \mathbb{R}^{m \times m}$.

Si m es grande la matriz $A^t A$
puede ser enorme y resolver

$$A^t A x = A^t b \quad \text{muy costoso.}$$

En este caso si hacemos la descompo-
sición QR de A (que asumimos
tiene columnas li)

$$\underbrace{\begin{pmatrix} a_1 & \dots & a_m \end{pmatrix}}_{A \in \mathbb{R}^{n \times m}} = \underbrace{\begin{pmatrix} q_1 & \dots & q_m \end{pmatrix}}_{Q \in \mathbb{R}^{n \times m}} \underbrace{\begin{pmatrix} r_{11} & r_{12} & \dots & r_{1m} \\ 0 & r_{22} & & r_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & r_{mm} \end{pmatrix}}_{R \in \mathbb{R}^{m \times m} \text{ con } r_{ii} \neq 0}$$

Donde Q es una matriz con columnas que forman un conjunto ortonormal y R es triangular superior invertible.

Entonces hacemos lo siguiente

$$\begin{array}{ccc} A & = & Q \cdot R \\ \uparrow & & \uparrow \quad \uparrow \\ \mathbb{R}^{n \times m} & \mathbb{R}^{n \times m} & \mathbb{R}^{m \times m} \end{array} \quad \begin{array}{l} Q \text{ tiene columnas} \\ \text{ortonormales con} \\ Q^t \cdot Q = Id \end{array}$$

y R es triangular invertible (los $r_{ii} \neq 0$).

$$\Rightarrow A^t A = R^t Q^t Q R = R^t R$$

$$\Rightarrow A^t A a = A^t b$$

}

$$R^t R a = R^t Q^t b \quad (R^t \text{ invertible})$$

$$\downarrow$$

$$R a = Q^t b \quad \text{con } R \text{ triangular sup}$$

Nota: $A^t A$ crucial pero mala para cómputo. Matrices ortogonales y triangulares son "las buenas".

Pseudo inversa de Penrose (mirar notas clase pasada)

Quedó para probar:

Ejercicio: $A \in \mathbb{K}^{m \times n}$

Si $m > n$ y $\text{rg}(A) = n$ (col de A son li.)

$$\Rightarrow A^T = (A^* A)^{-1} A^* \quad \text{y} \quad A^T A = \text{Id}$$

Dem: $A = U \begin{pmatrix} \sigma_1 & \dots & \sigma_m \\ & & 0 \end{pmatrix} V^*$ con $\sigma_m > 0$ ($\text{rg}(A) = m$)

$$\Rightarrow A^t = V \begin{pmatrix} \sigma_1^{-1} & & \\ & \ddots & \\ & & \sigma_m^{-1} \end{pmatrix} U^*, \quad A^* = V \Sigma^t U^*$$

$$\begin{aligned} \text{y } A^* A &= V \Sigma^t \underbrace{U^* U}_{Id} \Sigma V^* \\ &= V \begin{pmatrix} \sigma_1^2 & & \\ & \ddots & \\ & & \sigma_m^2 \end{pmatrix} V^* \end{aligned} \quad VV^* = V^*V = Id$$

$$\begin{aligned} \Rightarrow (A^* A)^{-1} A^* &= V \begin{pmatrix} \sigma_1^{-2} & & \\ & \ddots & \\ & & \sigma_m^{-2} \end{pmatrix} \underbrace{V^* V}_{Id} \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_m \end{pmatrix} U^* \\ &= V \begin{pmatrix} \sigma_1^{-1} & & \\ & \ddots & \\ & & \sigma_m \end{pmatrix} U^* = A^t \end{aligned}$$

luego, si las col de $A \in \mathbb{R}^{m \times n}$ son li, la única sol de $A^t A x = A^t b$ es $x = \underbrace{(A^t A)^{-1} A^t}_{= "A^T"} b$.

Ej de parcial:

En un bosque se ha identificado una especie de planta exótica. A lo largo de los últimos años se ha registrado cómo progresó el uso de individuos de dicha especie, se tienen los datos

año	$0^{=x_1}$	$1^{=x_2}$	$2^{=x_3}$	$3^{=x_4}$	$4^{=x_5}$	$5^{=x_6}$	$6^{=x_7}$
cant	216	219	287	303	439	556	681
indiv	"	"	"	"	"	"	"
	y_1	y_2	y_3	y_4	y_5	y_6	y_7

a) Hallar el poli de grado menor o igual a dos q' mejor ajuste a los datos en el sentido de los cuadrados mínimos.

Buscamos $P(x) = a_0 + a_1 x + a_2 x^2$:

$$\sum_{i=1}^7 \left(\underbrace{P(x_i) - y_i}_{(a_0 + a_1 x_i + a_2 x_i^2 - y_i)} \right)^2 \text{ sea mín.}$$

Es decir en

$$A = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \\ 1 & 4 & 16 \\ 1 & 5 & 25 \\ 1 & 6 & 36 \end{pmatrix} \quad y \quad b = \begin{pmatrix} 216 \\ 219 \\ 287 \\ 303 \\ 439 \\ 556 \\ 681 \end{pmatrix}$$

$$a_0, a_1, a_2: \quad \left\| A \begin{pmatrix} a_0 \\ a_1 \\ a_2 \end{pmatrix} - b \right\|_2^2 \text{ sea mín.}$$

y vemos que como las columnas de A son l_i (chequear), encontrar $\begin{pmatrix} a_0 \\ a_1 \\ a_2 \end{pmatrix}$

que haga $\|A \begin{pmatrix} a_0 \\ a_1 \\ a_2 \end{pmatrix} - b\|_2^2$ sea mín
equivale a encontrar $\begin{pmatrix} a_0 \\ a_1 \\ a_2 \end{pmatrix}$ solución de

$$\underbrace{A^t A}_{3 \times 3} \begin{pmatrix} a_0 \\ a_1 \\ a_2 \end{pmatrix} = \underbrace{A^t b}_{3 \times 1}$$

Ej: Programar y resolver en Python.

Si después me piden estimar cuántos individuos habrá en 100 años según este modelo haré $P(100)$.

b) Ajustar una función de la forma $g(x) = d_0 e^{d_1 x}$ aplicando cuadrados mínimos sobre la función transformada convenientemente.

Podríamos plantear la minimización (en función de d_0 y d_1) de

$$\sum_{i=1}^7 (g(x_i) - y_i)^2 = \sum_{i=1}^7 (d_0 e^{d_1 x_i} - y_i)^2$$

Pero vemos que el parámetro d_1 no es lineal dentro del cuadrado (como lo era para $P(x) = a_0 + a_1 x + a_2 x^2$).

Entonces no podemos usar la técnica anterior en donde reescribimos el problema de minimización equivalente $\|A \begin{pmatrix} a_0 \\ a_1 \\ a_2 \end{pmatrix} - b\|_2$.

Para buscar una aproximación y poder usar los resultados anteriores "linealizamos" nuestro problema tomando \ln . (logaritmo neperiano).
No estamos resolviendo el problema

de minimizar $\sum_{i=1}^7 (d_0 e^{d_1 x_i} - y_i)^2$

pero resolvemos uno similar:

Buscamos d_0, d_1 que minimice.

$$\sum_{i=1}^7 \left(\ln(d_0 e^{d_1 x_i}) - \ln y_i \right)^2$$

Nota: Dados $b > a > 1$, por el
teorema del valor medio, existe $c \in (a, b)$:

$$\ln b - \ln a = \underbrace{\frac{1}{e}}_{\left(\ln x \right)' \Big|_{x=c}} (b-a)$$

$$\text{como } c > 1 \Rightarrow \frac{1}{e} < 1$$

$$\Rightarrow |\ln b - \ln a| < |b - a|$$

$$\Rightarrow (\ln b - \ln a)^2 < (b - a)^2$$

De esta manera, si los y_i 's de los datos son grandes (como en el ejemplo) es de esperar que si usamos el d_0, d_1 encontrados con la linealización para el problema original, el error sea peor.

Volvamos al planteo de la linealización:

Buscamos d_0, d_1 que minimice.

$$\sum_{i=1}^7 \left(\ln(d_0 e^{d_1 x_i}) - \ln y_i \right)^2, \text{ es}$$

decir buscamos d_0, d_1 que haga mínimo

$$\sum_{i=1}^7 \left(\underbrace{\ln(d_0)}_{\text{lo llamamos } a_0} + \underbrace{d_1 x_i}_{\text{lo llamamos } a_1} - \underbrace{\ln y_i}_{\text{lo llamamos } \tilde{y}_i} \right)^2$$

este problema equivale a

$$\min_{a_0, a_1} \left\| A \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} - b \right\|_2$$

donde

$$A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \\ 1 & 6 \end{pmatrix} \quad y \quad b = \begin{pmatrix} \ln 216 \\ \ln 219 \\ \ln 287 \\ \ln 303 \\ \ln 439 \\ \ln 556 \\ \ln 681 \end{pmatrix}$$

\Rightarrow planteamos

$$A^t \cdot A \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = A^t b$$

Una vez que resolvemos y encontramos $a_0, a_1 \leadsto$ volvemos para atrás usando

$$\ln d_0 = a_0 \Rightarrow d_0 = e^{a_0}$$

$$d_1 = a_1$$

c) Para el mismo problema podemos encontrar un polinomio de grado 3, grado 4, etc que mejor aproxime en el sentido de los cuadrados mínimos?

En general, dada una tabla de datos

x	x_1	x_2	\dots	x_m
y	y_1	y_2	\dots	y_m

se busca un polinomio de grado menor o igual a m que mejor aproxime a mis datos en el sentido de los cuadrados mínimos.

Buscamos a_0, a_1, \dots, a_m ($m+1$ incógnitas)

de manera que si $P(x) = a_0 + a_1x + \dots + a_mx^m$

$$\sum_{i=1}^m (P(x_i) - y_i)^2 \text{ sea mínimo.}$$

Planteamos

$$A = \begin{pmatrix} 1 & x_1 & x_1^2 & \dots & x_1^m \\ \vdots & x_2 & x_2^2 & & \vdots \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_m & x_m^2 & \dots & x_m^m \end{pmatrix} \in \mathbb{R}^{n \times m}$$

$$y \quad b = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}$$

El problema es equivalente a
buscar un mínimo de

$$\left\| A \begin{pmatrix} a_0 \\ \vdots \\ a_m \end{pmatrix} - b \right\|_2$$

y vimos que si las columnas de A
son li \Rightarrow la única solución viene
dada por $A^t A \begin{pmatrix} a_0 \\ \vdots \\ a_m \end{pmatrix} = A^t b.$

La pregunta es: cuándo puedo garantizar que las columnas son li?

Para empezar como $A \in \mathbb{R}^{n \times m}$, se tienen $m+1$ columnas que son vectores de \mathbb{R}^m .

Si queremos que haya posibilidad de que sean li, debe ser $m+1 \leq m$

Cuando $m+1 = m$

$$A = \begin{pmatrix} 1 & x_1 & x_1^2 & \dots & x_1^{m-1} \\ \vdots & x_2 & x_2^2 & & \vdots \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_m & x_m^2 & \dots & x_m^{m-1} \end{pmatrix} \quad \begin{array}{l} \text{se conoce} \\ \text{como} \end{array}$$

matriz de Vandermonde y se nota $V[x_1, x_2, \dots, x_m]$.

Veamos que en este caso cuando $V[x_1, \dots, x_m]$ es una matriz invertible. Para eso calculemos su determinante por

inducción.

$$\det V[x_1, x_2] = \det \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \end{pmatrix} = x_2 - x_1$$

Vamos a usar que hacer operaciones de columna $C_i + \alpha C_j \rightarrow C_i$ no

cambia el determinante de una matriz

y que el determinante de multiplicar una columna por un escalar es igual a ese escalar por el determinante.

Es decir, vale que:

$$\begin{aligned} \bullet \det(C_1, C_2, C_i + \alpha C_j, \dots, C_n) \quad i \neq j \\ = \det(C_1, C_2, C_i, \dots, C_n) \end{aligned}$$

$$\begin{aligned} \bullet \det(C_1, \dots, \alpha C_i, \dots, C_n) \\ = \det(C_1, \dots, C_i, \dots, C_n) \end{aligned}$$

y lo mismo por filas.

$$\det V[x_1, x_2, x_3] = \det \begin{pmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \end{pmatrix}$$

$$= \det \begin{pmatrix} 1 & 0 & 0 \\ 1 & x_2 - x_1 & x_2^2 - x_1 x_2 \\ 1 & x_3 - x_1 & x_3^2 - x_1 x_3 \end{pmatrix}$$

$$C_3 - x_1 C_2 \rightarrow C_3$$

$$C_2 - x_1 C_1 \rightarrow C_2$$

$$= \det \begin{pmatrix} x_2 - x_1 & x_2^2 - x_1 x_2 \\ x_3 - x_1 & x_3^2 - x_1 x_3 \end{pmatrix}$$

$$= \det \begin{pmatrix} \underline{x_2 - x_1} & \underline{(x_2 - x_1)} x_2 \\ \underline{x_3 - x_1} & \underline{(x_3 - x_1)} x_3 \end{pmatrix}$$

$$= (x_2 - x_1)(x_3 - x_1) \cdot \det \begin{pmatrix} 1 & x_2 \\ 1 & x_3 \end{pmatrix}$$

$$= (x_2 - x_1)(x_3 - x_1)(x_3 - x_2)$$

Usando la misma idea para el caso general se prueba que

$$\det V[x_1 \dots x_n] = \prod_{n \geq j > i \geq 1} (x_j - x_i)$$

Con lo cual vemos que esta matriz es invertible si y solo si $x_i \neq x_j \forall i \neq j$. Es decir los x_i 's de la tabla son todos distintos.

Volvamos al caso general con $m \leq n-1$.
Vimos que si $m = n+1$ y $x_i \neq x_j \forall i \neq j$ entonces $V[x_1 \dots x_m]$ es invertible \Rightarrow el rango de la matriz es n , es decir, sus columnas son l.i.

Con lo cual si me quedo con un subconjunto de $m < n-1$ columnas también serán l.i.

En conclusión, dada una tabla de n datos con $x_i \neq x_j \forall i \neq j$, existe un único polinomio de grado menor o igual a $m (\leq n-1)$

que mejor aproxima a la tabla en el sentido de los cuadrados mínimos.

OBS:

- Si los x_i están muy cerca entre sí provoca oscilaciones muy altas
- Si m es muy grande cercano a $n-1$ también produce oscilaciones especialmente cerca de los extremos.
(Fenómeno de Runge).

Polinomio interpolador: Con $x_i \neq x_j \forall i \neq j$

Para $m = n-1$ se sabe que existe un único polinomio de grado menor o igual a $n-1$ que satisface

$$P(x_i) = y_i \quad i = 1, \dots, n.$$

Es decir, este polinomio pasa

por cada punto (x_i, y_i) .

Se lo llama polinomio interpolador de Lagrange.

Podemos encontrarlos como antes planteando $A = V[x_1 \dots x_n]$ y resolviendo

$$A^t A \begin{pmatrix} a_0 \\ \vdots \\ a_{n-1} \end{pmatrix} = A^t \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}.$$

Si no, podemos usar la base de Lagrange:

Para cada x_j con $j=1 \dots n$,


definimos $l_j(x)$ el polinomio mónico que satisface:

$$l_j(x_i) = 0 \quad \text{si } i \neq j$$

$$l_j(x_j) = 1,$$

Usamos
 $x_i \neq x_j$.

es decir

$$l_j(x) = \frac{\prod_{i \neq j} (x - x_i)}{\prod_{i \neq j} (x_j - x_i)}$$


$$\Rightarrow P(x) = \sum_{j=1}^n y_j L_j(x)$$

Veamos que P es único. Supongamos
existe otro q de grado menor o igual a

$$n-1 : \quad q(x_j) = y_j \quad \forall j=1 \dots n$$

$$\Rightarrow (p - q)(x_j) = 0 \quad \forall j=1 \dots n \quad (*)$$

y $p - q$ tiene grado menor o igual

a $n-1 \Rightarrow$ tiene a lo sumo $n-1$

raíces, lo cual se contradice con $(*)$.

Error de interpolación: Sean $f \in C^n[a, b]$

y P el poli interpolador de grado $\leq n-1$

en los puntos x_1, \dots, x_n . Para cada $x \in [a, b]$

existe $\xi = \xi(x) \in [a, b]$:

$$E(x) = f(x) - P(x) = \frac{f^{(n)}(\xi)}{n!} \prod_{i=1}^n (x - x_i)$$